Knowledge Distillation

1.Uvod

U poslednjih nekoliko godina duboke neuronske mreže postigle su izuzetne rezultate u različitim oblastima mašinskog učenja, kao što su klasifikacija slika, obrada prirodnog jezika i prepoznavanje govora. Međutim, savremeni modeli često sadrže veliki broj parametara, što dovodi do visokih zahteva u pogledu memorije i računarskih resursa. Zbog toga njihova primena na uređajima sa ograničenim resursima, kao što su mobilni telefoni ili ugrađeni sistemi, može biti otežana.

Jedan od pristupa rešavanju ovog problema predstavlja tehnika poznata kao knowledge distillation. Osnovna ideja ove metode je da se znanje velikog i kompleksnog modela (tzv. *teacher model*) prenese na manji i efikasniji model (tzv. *student model*). Student model se trenira tako da imitira ponašanje teacher modela, čime je moguće zadržati visok nivo tačnosti uz značajno smanjenje broja parametara.

Koncept knowledge distillation-a prvi su formalno predstavili Hinton i saradnici u radu *Distilling the Knowledge in a Neural Network* [1]. U ovom radu autori predlažu treniranje student modela korišćenjem tzv. *soft targets*, odnosno verovatnoća koje generiše teacher model, čime student dobija više informacija nego pri standardnom učenju na osnovu tačnih oznaka (*dark knowledge*). Ovaj pristup omogućava student modelu da bolje generalizuje i često postiže rezultate bliske teacher modelu uprkos znatno manjoj kompleksnosti.

U okviru ovog projekta implementiran je i ispitan pristup zasnovan na knowledge distillation metodi, sa ciljem da se ispita u kojoj meri je moguće smanjiti kompleksnost modela uz zadržavanje prihvatljive tačnosti na posmatranom skupu podataka.

2.Opis rešenja

Rešenje je implementirano u Google Collab okruženju koristeći Tensorflow. Za treniranje i evaluaciju modela korišćen je CIFAR-10 skup podataka, koji sadrži 60 000 kolor slika dimenzija 32×32 piksela raspoređenih u 10 klasa.

Napravljen je složeniji teacher model od 2.2 miliona parametara i student model sa oko 175 hiljada parametara. Pri konstruisanju ovih arhitektura korišćeni su L2 regularizacija, Batch Normalization i Dropout kako bi se izbeglo preprilagođavanje i stabilizovalo učenje.

Teacher je treniran na transformisanim CIFAR-10 podacima, što mu omogućava da vidi različite varijacije iste slike, čime poboljšava mogućnost generalizacije. Napravljen je moćan model čija je tačnost oko 91%.

Student model trenira koristeći knowledge distillation, gde uči iz dve vrste informacija: hard labels i soft targets. Hard labels su stvarne oznake iz skupa podataka, dok su soft targets verovatnoće koje generiše teacher model. Primena temperature T omekšava raspodelu verovatnoća teacher modela, čime student dobija više informacija o sličnosti između klasa.

Funkcija gubitka u knowledge distillation-u kombinuje dve komponente:

- **Hard loss** – unakrsna entropija između predikcija student modela i hard labels, koja meri koliko se predikcije studenta razlikuju od stvarnih klasa.

- **Soft loss** – KL divergencija između soft targets teacher-a i predikcija studenta, skalirana temperaturom T^2

Ukupan loss student modela se računa na sledeći način:

$L_{student} = \alpha * L_{hard} + (1 - \alpha) * L_{soft}$, gde je

$L_{soft} = T^2 * KL(p_{teacher} || p_{student})$

Skaliranje sa T^2je potrebno zato što primena temperature omekšava raspodelu verovatnoća teacher modela. Bez ovog faktora gradijenti soft loss-a bi bili preniski, što bi otežalo učenju studenta.

Parametar α nam predstavlja težinu odnosno koliko student veruje teacheru naspram stvarnih labela.

3.Eksperimentalni rezultati

Eksperiment je sproveden u Google Collab okruženju. Student je treniran na 80 epoha. Kao optimizer je korišćen Adam sa LR = 0.001 (learning rate). Za temperaturu je izabrano $T = 5$, što je i često korišćena temperatura u literaturi, jer dovoljno omekšava verovatnoće.

Class: ship

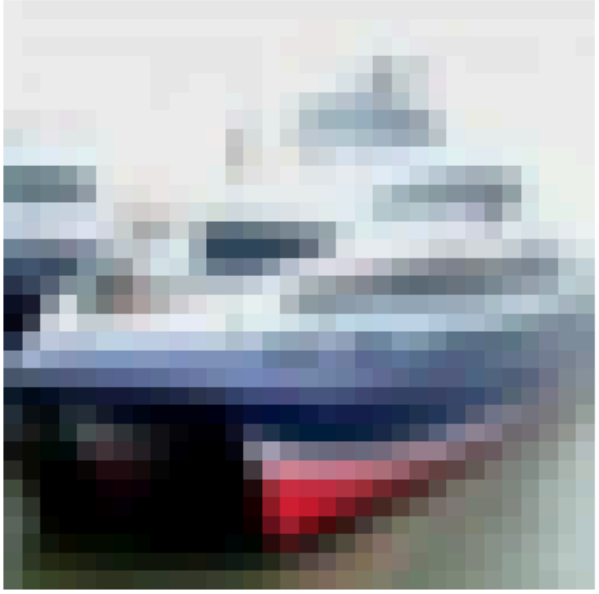

	airplane	automobile	bird	cat	deer	dog	frog	horse	ship	truck
softmax(logits)	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	1.0000	0.0000
softmax(logits/T)	0.0083	0.0295	0.0004	0.0006	0.0001	0.0002	0.0004	0.0001	0.9547	0.0057

Class: cat

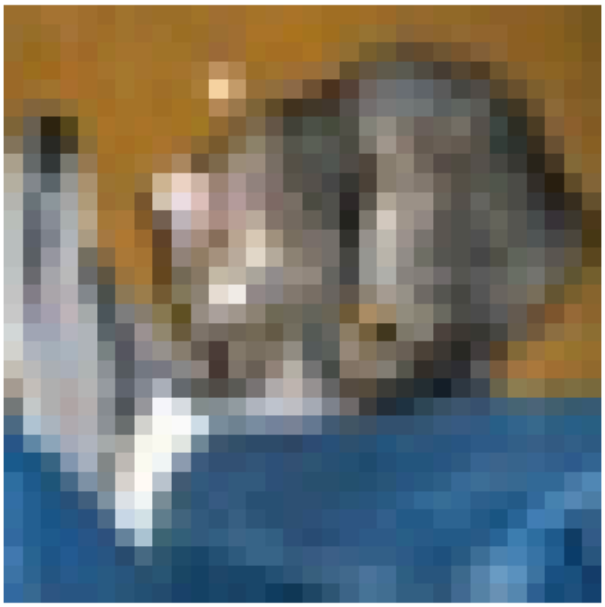

	airplane	automobile	bird	cat	deer	dog	frog	horse	ship	truck
softmax(logits)	0.0000	0.0000	0.0001	0.9985	0.0000	0.0013	0.0000	0.0000	0.0000	0.0000
softmax(logits/T)	0.0131	0.0066	0.1077	0.6366	0.0122	0.1697	0.0290	0.0128	0.0082	0.0042

Takođe je odabran parametar $\alpha = 0.2$ čime se mnogo veći akcenat stavlja na učenje od kompleksnog teachera nego na same podatke. Za batch size smo odabrali 256, jer je trening bio prespor sa manjim i nije bilo primetno značajno unapređenje. Koristili smo i exponential decay gde smo smanjivali learning rate sa faktorom 0.8 na svakih 15 epoha.

Dobijen je model sa tačnošću na test skupu od oko 83%, a potom je i pod istim uslovima treniran drugi student bez knowledge distillation-a. Njegovi rezultati su se pokazali slabijim, obzirom na to da smo postigli tačnost od 79%. Dobili smo poboljšanje od oko 3-4% što pokazuje da je knowledge distillation prošao uspešno.

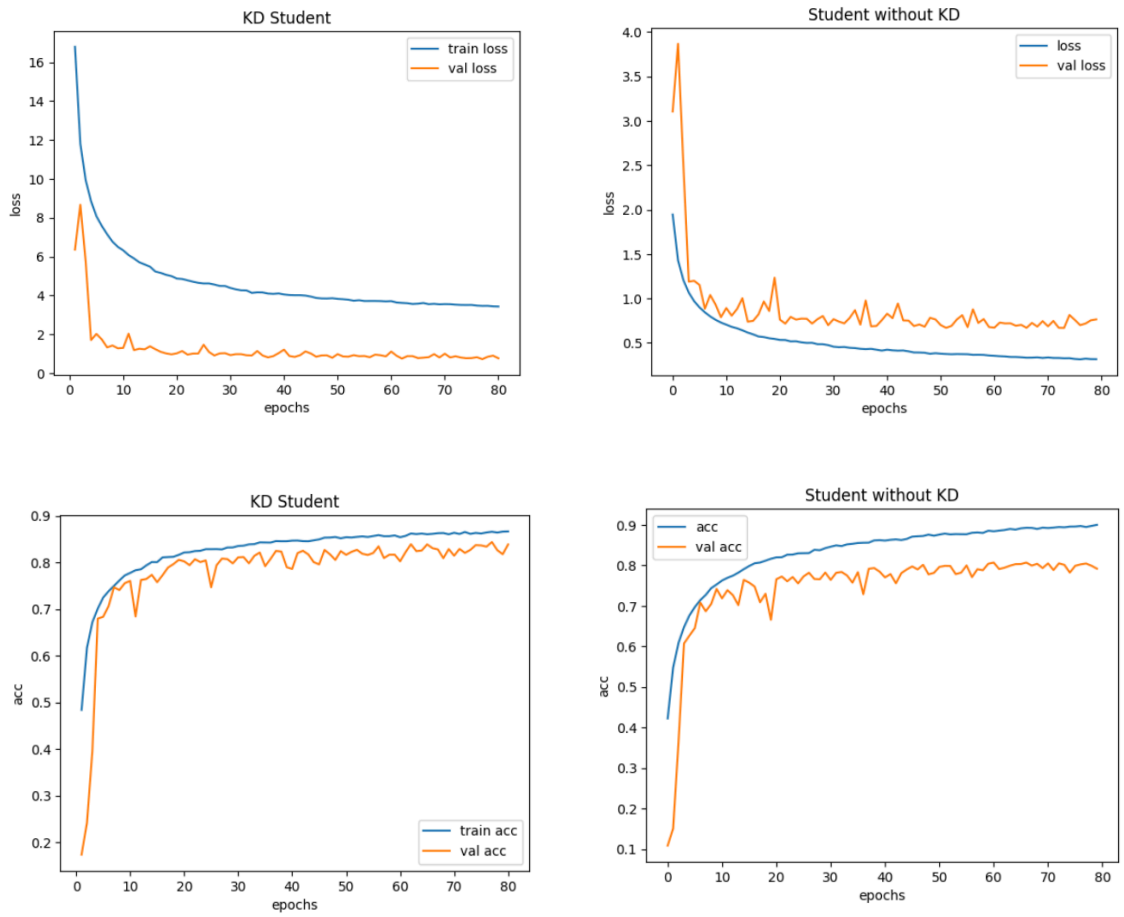

4.Zaključak

Pokazalo se da student postiže bolje rezultate (3-4% tačnosti razlike) kada uči od teachera naspram toga kada uči sam. Dobili smo 12 puta manji model od teacher modela sa prihvatljivom tačnošću. Mana je što smo izgubili oko 8% tačnosti u odnosu na teacher model, ali uzimajući u obzir ovoliku kompresiju modela, takav rezultat je i očekivan. Dalje unapređenje ovog metoda može podrazumevati eksperimentisanje sa parametrima T i α, promena arhitekture studenta ili učenje nad transformisanim podacima nad kojima je učio i teacher.

5.Literatura

1. *Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the Knowledge in a Neural Network.*
2. *Cho, J. H., & Hariharan, B. (2019). On the Efficacy of Knowledge Distillation.*
3. *Hernandez, D. E., Chang, J. R., & Nordling, T. E. M. (2022). Model compression using knowledge distillation with integrated gradients.*
4. *Frank, L., & Davis, J. (2021). What Makes a Good Dataset for Knowledge Distillation?*
5. *https://www.ibm.com/think/topics/knowledge-distillation*